بسمه تعالى

گزارش تكليف عملى درخت تصميم

امين اله زكى زاده

99123038

قسمت اول

برای انجام این آزمایش ستون ها ی فایل CSV داده شده مقدار نداشتند به همین علت خود نام ستون ها را اضافه نمودم ، به همین دلیل دیتاست ها را نیز پیوست می نمایم.

برای ایجاد یک درخت تصمیم نیاز به یک تابع جستوجو گر برای پیدا نمودن تعداد زیر ویژگی ها داخل هر گروه ویژگی است که در نتیجه ی آن بتوان آنتروپی حساب کرد و بهترین گروه ویژگی را برای گره پیدا کرد . همچنین نیاز به محاسبه ی آنتروپی و IG داریم .

این دو گروه کار در فایل entropy_v1.py انجام می شود ه دارای محتویات زیر است:

```
numerator = np.append(numerator, num) # putting each sub feature
```

تابع search_csv برای پیدا کردن انواع زیر ویژگی هاست که در دیکشنری whole_dict می ریزد و تابع search_class برای پیدا کردن تعداد هر کدام از آن ها و ریختن در همان دیکشنری است . تابع inf_gain ابتدا آنتروپی را برای یک دیتا فریم داده شده برای هر کلاس پیدا می کند سپس یک آرایه از information_gain ها برمیگرداند که برای هر هشت کلاس(البته برای کلاس های کمتر و بیشتر هم خود را منطبق می کند) مقدار دارد .

یک تابع برای جستو جوی درخت برای پیدا کردن شاخه ی منطبق با یک داده تست نیاز داریم که داخل فایل evaluat_v1.py با محتویات زیر وجود دارد و نام آن تابع eval است که درخت به دست آمده و دیتا فریم تست یا validation را دریافت می کند و میزان دقت را با عددی بین 0 و 1 برمی گرداند . یک داده ی test را بر می دارد و کل آرایه ی درخت را به دنبال دیکشنری منطبق با کلاس و ویژگی آن می گردد . اگر در شاخه ای یک کلاس یک ویژگی یا یک کلاس در داده test برابر نباشد break می کند و شاخه دیگر را امتحان می کند . بعد از پیدا کردن شاخه منطبق break می کند و لیبل دیتاست test را با لیبل دیکشنری شاخه مقایسه می کند . اگر با هم برابر باشند is_eql
یکی اضافه می شود در غیر این صورت is_neq یکی اضافه می شود . در نهایت نسبت is_eql به کل دقت مورد نظر را می دهد.

برای پیدا نمودن درخت هم فایل tree_maker_v5.py وجود دارد که حاوی سه تابع است .

تابع find_root برای پیدا کردن ریشه ی درخت و initial کردن آرایه ی درخت نیاز است . یک درخت یک آرایه است که داخل آن گروه های لیبل خورده به صورت دیکشنری حاوی همه ی کلاس ها ی شاخه به عنوان key و ویژگی آن کلاس به عنوان value وجود دارد . محتویات دیکر دیکشنری یک شاخه شامل key های depth که عمق یک شاخه را نشان می دهد ، label که لیبل آن شاخه را نشان می دهد ، vote که در صورت یک بودن نشان می دهد اطلاعات کافی برای یک شاخه وجود نداشته و با voting لیبل خورده ، vote که یک بودن آن نشان دهنده آن است که یک شاخه تا حداکثر عمق رفته و لیبل های متفاوتی برای آن شاخه وجود داشته در نتیجه متداول ترین لیبل را خورده.

تابع labeler تنها برای لیبل زدن root در صورت امکان استفاده می شود و برای گره های بعدی به صورت داخلی در تابع continue_tree برای لیبل زدن مابقی گره ها استفاده می شود.

```
\sharp differece to v2 is that in v2 branches was more than data in train frame so i though its reason is that we have \sharp branches even at places with no sub-feature , assume that we are at a node , when we want to make a sub-feature \sharp we even include those sub-features that are excluded in that node because of data shortage at a specific node ,
```

```
if np.array(np.where(arr == '<=50K')).shape[1] < (len(arr) -</pre>
        if np.array(np.where(arr == '<=50K')).shape[1] == len(arr):
for i in dicti[datafrm random.columns.tolist()[rt place +
```

```
ind delete = np.append(ind delete, np.argwhere(tree == i))
   alpha = temp frame.columns.tolist()[rt place + 1]
```

```
lab temptemp frame = lab temp frame[lab temp frame[alpha]
'>50K')).shape[1]
                    tree = np.append(tree, temp i)
```

```
#
# train = pd.read_csv("adult.train.10k.discrete.csv")
#
# random_train = train.sample(frac=1)
#
# tree = []
# tree = find_root(random_train, tree)
# print(tree)
# continue_tree(random_train, tree)
```

در نهایت برای گزارش های خواسته شده در تکلیف یک فایل taklif.py ایجاد شده که توابع بالا را با درصد های متفاوت داده print آموزش می دهد و روی کل داده های خواسته شده را test درخت به دست آمده را تست می کند و در خروجی داده های خواسته شده را می کند.

```
import pandas as pd
        tree = continue tree(train, tree)
np.divide(np.sum(train eval), 5))
```

نتیجه ی چاپ شده به صورت زیر است:

round 0 with percentage 25 wait until result round 0 with percentage 25 train eval is 0.8932 test eval 0.8107594228833463 length of tree is 662 depth of tree is 8 round 1 with percentage 25 wait until result round 1 with percentage 25 train_eval is 0.902 test_eval 0.8047987442538401 length of tree is 651 depth of tree is 8 round 2 with percentage 25 wait until result round 2 with percentage 25 train_eval is 0.9004 test_eval 0.809361608614438 length of tree is 626 depth of tree is 8 round 3 with percentage 25 wait until result round 3 with percentage 25 train_eval is 0.8988 test_eval 0.8031575411488076 length of tree is 699 depth of tree is 8 round 4 with percentage 25 wait until result round 4 with percentage 25 train eval is 0.9072 test eval 0.805555555555556 length of tree is 645 depth of tree is 8 average train_eval with percentage 25 is 0.90032 average test eval percentage 25 is 0.8067265744911974

round 0 with percentage 35 wait until result round 0 with percentage 35 train_eval is 0.8911428571428571 test_eval 0.8156004861341288 length of tree is 863 depth of tree is 8 round 1 with percentage 35 wait until result round 1 with percentage 35 train eval is 0.8908571428571429 test eval 0.811327003753588 length of tree is 829 depth of tree is 8 round 2 with percentage 35 wait until result round 2 with percentage 35 train_eval is 0.8877142857142857 test_eval 0.8071689346166612 length of tree is 839 depth of tree is 8 round 3 with percentage 35 wait until result round 3 with percentage 35

train_eval is 0.9008571428571429 test_eval 0.8096077567210225

length of tree is 823

depth of tree is 8

round 4 with percentage 35 wait until result

round 4 with percentage 35

train eval is 0.89 test eval 0.8149314144366989

length of tree is 896

depth of tree is 8

average train eval with percentage 35 is 0.8921142857142857

average test_eval percentage 35 is 0.81 172711913242

round 0 with percentage 45 wait until result

round 0 with percentage 45

train_eval is 0.8871111111111111 test_eval 0.8067606254129046

length of tree is 1006

depth of tree is 8

round 1 with percentage 45 wait until result

round 1 with percentage 45

train_eval is 0.884222222222222 test_eval 0.8069476712025666

length of tree is 1039

depth of tree is 8

round 2 with percentage 45 wait until result

round 2 with percentage 45

train eval is 0.8811111111111111 test eval 0.8066121185316232

length of tree is 1046

depth of tree is 8

round 3 with percentage 45 wait until result

round 3 with percentage 45

train_eval is 0.88888888888888888 test_eval 0.8118238443885915

length of tree is 1031

depth of tree is 8

round 4 with percentage 45 wait until result

round 4 with percentage 45

train_eval is 0.8848888888888888 test_eval 0.817047817047817

length of tree is 1037

depth of tree is 8

average train_eval with percentage 45 is 0.8852444444444444

average test_eval percentage 45 is 0.8098384153167005

round 0 with percentage 55 wait until result

round 0 with percentage 55

train_eval is 0.8852727272727273 test_eval 0.8148472571991678

length of tree is 1200

depth of tree is 8

round 1 with percentage 55 wait until result

round 1 with percentage 55

train_eval is 0.8747272727272727 test_eval 0.819934282584885

length of tree is 1225

depth of tree is 8

round 2 with percentage 55 wait until result

round 2 with percentage 55

train_eval is 0.8858181818181818 test_eval 0.8200589970501475 length of tree is 1145 depth of tree is 8 round 3 with percentage 55 wait until result round 3 with percentage 55 train eval is 0.8845454545454545 test eval 0.8101613080215078 length of tree is 1260 depth of tree is 8 round 4 with percentage 55 wait until result round 4 with percentage 55 train eval is 0.8847272727272727 test eval 0.8182615367751837 length of tree is 1206 depth of tree is 8 average train eval with percentage 55 is 0.88301818181819 average test eval percentage 55 is 0.8166526763261783 round 0 with percentage 65 wait until result round 0 with percentage 65 train_eval is 0.8878461538461538 test_eval 0.8124455100261552 length of tree is 1387 depth of tree is 8 round 1 with percentage 65 wait until result round 1 with percentage 65 train eval is 0.88 test eval 0.8179143510951291 length of tree is 1386 depth of tree is 8

round 0 with percentage 65 wait until result round 0 with percentage 65 train eval is 0.8878461538461538 test eval 0.8124455100261552 length of tree is 1387 depth of tree is 8 round 1 with percentage 65 wait until result round 1 with percentage 65 train eval is 0.88 test eval 0.8179143510951291 length of tree is 1386 depth of tree is 8 round 2 with percentage 65 wait until result round 2 with percentage 65 train eval is 0.8832307692307693 test eval 0.8127450980392157 length of tree is 1348 depth of tree is 8 round 3 with percentage 65 wait until result round 3 with percentage 65 train eval is 0.8838461538461538 test eval 0.8110894097222222 length of tree is 1337 depth of tree is 8 round 4 with percentage 65 wait until result

round 4 with percentage 65 train_eval is 0.882 test_eval 0.8183304272013949 length of tree is 1353 depth of tree is 8 average train_eval with percentage 65 is 0.8833846153846153 average test_eval percentage 65 is 0.8145049592168234

round 0 with percentage 75 wait until result round 0 with percentage 75 train eval is 0.881733333333334 test eval 0.81671012603216 length of tree is 1490 depth of tree is 8 round 1 with percentage 75 wait until result round 1 with percentage 75 train eval is 0.8768 test eval 0.8149751136117723 length of tree is 1543 depth of tree is 8 round 2 with percentage 75 wait until result round 2 with percentage 75 train eval is 0.8805333333333333 test eval 0.8149913344887348 length of tree is 1482 depth of tree is 8 round 3 with percentage 75 wait until result round 3 with percentage 75 train eval is 0.8809333333333333 test eval 0.8203703703704 length of tree is 1540 depth of tree is 8 round 4 with percentage 75 wait until result round 4 with percentage 75 train_eval is 0.87826666666666666 test_eval 0.8121119703735976 length of tree is 1548 depth of tree is 8 average train_eval with percentage 75 is 0.879653333333333333 average test eval percentage 75 is 0.8158317829753271

round 0 with percentage 100 wait until result round 0 with percentage 100 train_eval is 0.8754 test_eval 0.8186136903476571 length of tree is 1900 depth of tree is 8 round 1 with percentage 100 wait until result

round 1 with percentage 100 train eval is 0.8754 test eval 0.8186136903476571 length of tree is 1900 depth of tree is 8 round 2 with percentage 100 wait until result round 2 with percentage 100 train eval is 0.8754 test eval 0.8186136903476571 length of tree is 1900 depth of tree is 8 round 3 with percentage 100 wait until result round 3 with percentage 100 train eval is 0.8754 test eval 0.8186136903476571 length of tree is 1900 depth of tree is 8 round 4 with percentage 100 wait until result round 4 with percentage 100 train eval is 0.8754 test eval 0.8186136903476571 length of tree is 1900 depth of tree is 8 average train_eval with percentage 100 is 0.8754 average test eval percentage 100 is 0.8186136903476571

در بالا مشاهده شد که تا 45 درصد داده دقت 80 درصد بود اما با افزایش تعداد داده ها درخت فقط بزرگتر شد از لحاظ طول و دقت بر روی داده های train تغییری نکرد.

قسمت دوم: انجام هرس

برای هرس کردن به این صورت عمل شده که به علت طولانی بودن عملیات evaluate و گرفتن زمان فراوان برای پیدا کردن دقت درخت بعد از حذف هر گره ، برای انجام عمل هرس چهار ستون از کلاس ها و 90 درصد ردیف ها حذف شدند و یک درخت بر اساس آن ها تشکیل شد و عمل هرس برای آن ها صورت گرفت .

به همان روش گفته شده در کلاس یعنی گرفتن کاندید و سپس حذف یک گره و پیدا کردن validation بر روی درخت یافت شده و سپس حذف گروهی با بیشترین مقدار دفت ایجاد شده جلو رفتم که نتیجه ی آن فایلی به صورت زیر و با نام pruning.py شد .

در آن سه تابع وجود دارد.

تابع prune_session برای پیدا کردن بهترین گره برای حذف استفاده می شود و در خروجی مقدار دقت بر روی درخت هرس شده ی به دست آمده و خود آن درخت را بر می گرداند .

تابع node_counter برای شمردن تعداد گره های درخت هرس شده در هر بار به دست آمدن یک درخت هرس شده به منظور رسم نمودار های خطا بر روی validation و test است .

در نهایت تابع prune از تابع prune_session تا جایی که 0.5 درصد برتری در validation دیده شود عمل pruning را انجام می دهد و در هر بارگره ها را می شمرد و بر روی اخت test میزان خطا را بر روی یک آرایه ذخیره می کند. در نهایت هم نمودار های خواسته شده را رسم می کند و درخت هرس شده را برمی گرداند .

در برنامه زیر 25 درصد از داده های train برای validation انتخاب شده است . برنامه تا جایی پیش میرود که خطای داده های validation به اندازه 5 درصد نسبت به حذف گره آخر بهتر عمل کرده باشد .(با توجه به

داخل تابع prune)

تابع prune هم از prune_session استفاده می کند و یک دور گره های انتهایی را امتحان می کند در صورتی که بهترین validation را حساب کند و 0.5 درصد بهتر عمل کند نسبت به قبل آن هرس را اعمال می کند تا وقتی که این شرط زیر پا گذاشته شود. سپس بر اساس آرایه های nodes و val_eval و train_eval عمل رسم انجام می شود که در هر مرحله اندازه ی خطا و تعداد نود ها در آن ها ذخیره شده بود.

```
import numpy as np
   app_tree_grp = [] # every tree before eval is saved here
           temp bran = dict.copy(branch)
```


```
app_brnch['label'] = None
            for brch in temp_prnd_tr: # process of deleting similar branches
branch dict key[dont check last node]: # check the keys to be equal # edited
branch[branch dict key[dont check last_node]]:
                                    tmp brch = dict.copy(brch)
```

```
temp prnd tr = np.delete(temp prnd tr, deletion grp)
               temp frame = pd.DataFrame.copy(train data)
                   arr = temp frame.pop('label').to numpy() # edited
'<=50K')).shape[1]):
   branch keeper = np.array([])
       branch maker = np.array([])
```

```
branch keeper = np.append(branch keeper, {'key':
train eval = np.append(train eval, 1. - eval(train data, 100, tree))
nodes = np.append(nodes, node counter(tree))
```

```
plt.plot(nodes, test_eval, 'b', label='test')
train = pd.read csv("adult.train.10k.discrete.csv")
train = train.drop(columns=[' race', ' sex', ' native-country', '
test = pd.read csv('adult.test.10k.discrete.csv')
test = test.sample(frac=.1)
tree = continue tree(train, tree)
prune(tree, train, validate, test)
```

نمودار زیر در نهایت به دست می آید که از جایی شروع شده که دقت روی داده های validation شروع به کم شدن کرده . در نمودار زیر مشاهده می شود دقت همچنان در حال افزایش از 72 گره به بعد روی داده های train را نشان می دهد در حالی که از 72 گره به بعد برای داده های validate و از 73گره به بعد برای داده های test شاهد کم شدن دقت و افزایش خطا هستیم. در نتیجه می توان گفت از گره 73 به بعد شاهد می می توان گفت از گره 73 به بعد شاهد می می توان گفت از گره 73 به بعد شاهد می توان گفت از گره 73 به بعد شاهد می توان گفت از گره 73 به بعد شاهد می توان گفت از گره 73 به بعد شاهد می توان گفت از گره 73 به بعد شاهد می توان گفت از گره 73 به بعد شاهد می توان گفت از گره به بعد شاهد کم شدن دقت و افزایش خطا هستیم.



همین عمل را با انتخاب 25 درصد داده های validation از روی دیتاست های test تکرار می کنیم. این بار برای مشاهده ی کل کمی قبل نر از overfitting را هم نشان دهد پس خط زیر را :

```
while total_val_eval < (prn_eval - .005):

while total_val_eval < (prn_eval + .003):

if total_val_eval < (prn_eval - .005):

if total_val_eval < (prn_eval - .005):

if total_val_eval < (prn_eval + .003):</pre>
```

و خطوط زیر را که داده validation را از train بر می داشت:


```
train = pd.read_csv("adult.train.10k.discrete.csv")
train = train.sample(frac=.1)
train = train.drop(columns=[' race', ' sex', ' native-country', '
workclass'])
validate = train.sample(frac=.25)
train = train.drop(index=validate.index.to_numpy())
# random_train = train.sample(frac=1)
test = pd.read_csv('adult.test.10k.discrete.csv')
test = test.drop(columns=[' race', ' sex', ' native-country', ' workclass'])
test = test.sample(frac=.1)
```

به زیر تغییر می دهیم:

```
train = pd.read_csv("adult.train.10k.discrete.csv")
train = train.sample(frac=.1)
```

```
train = train.drop(columns=[' race', ' sex', ' native-country', '
workclass'])
# random_train = train.sample(frac=1)
test = pd.read_csv('adult.test.10k.discrete.csv')
test = test.drop(columns=[' race', ' sex', ' native-country', ' workclass'])
test = test.sample(frac=.1)
validate = test.sample(frac=.1)
test = test.drop(index=validate.index.to_numpy())
```

با تكرار دوباره بالا نمودار زير را داريم:




اگر فقط چند آرایه ی اول را برداریم و رسم کنیم:

```
nodes = np.array([])
val eval = np.array([])
test_eval = np.array([])
train eval = np.array([])
nodes = np.load('nodes.npy',allow_pickle=True)
val_eval = np.load('val_eval.npy', allow_pickle=True)
train_eval = np.load('train_eval.npy', allow_pickle=True)
test_eval = np.load('test_eval.npy', allow_pickle=True)
val_eval = np.load('val_eval.npy', allow_pickle=True)
nodes = nodes[0:15]
train_eval = train_eval[0:15]
test_eval = test_eval[0:15]
val_eval = val_eval[0:15]
plt.plot(nodes, val_eval, 'r', label='eval')
plt.plot(nodes, test_eval, 'b', label='test')
plt.plot(nodes, train_eval, 'g', label='train')
plt.xlabel('nodes')
```

plt.ylabel('error')
plt.legend()
plt.show()

نتيجه :



نتیجه در گره 79 نشان می دهد دیتای validation دچار افزایش خطا می شود . این افزایش خطا را در گره 75 در داده های test می توان مشاهده نمود . در نتیجه می توان گفت overfitting بعد از گره 75 به بعد دیده می شود.